

1. Guion de la reunión

La idea en un minuto (decirlo sin leer)

“Mi TFG va de **SVM con kernels cuánticos**. La SVM solo necesita **productos escalares** entre los datos, que es el kernel. Un ordenador cuántico calcula de forma natural productos escalares entre estados. La idea es **codificar cada dato en un estado** con un circuito y **estimar el kernel midiendo**. La optimización sigue siendo **clásica y convexa**. Voy a implementarlo yo, compararlo con kernels clásicos y estudiar sus limitaciones.”

Desarrollo (2–3 minutos)

1. **SVM**. Busca el hiperplano de margen máximo. En el dual, los datos solo aparecen como $\mathbf{x}_i^T \mathbf{x}_j$.
2. **Truco del kernel**. Sustituir $\mathbf{x}_i^T \mathbf{x}_j$ por $K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$: trabajar en un espacio más grande sin calcular ϕ (sección 3).
3. **Lo cuántico**. n qubits viven en $\mathbb{C}^{2^n}$. Cada dato se codifica como $|\phi(\mathbf{x})\rangle = U(\mathbf{x})|0 \cdots 0\rangle$ y el kernel es la fidelidad

$$K(\mathbf{x}, \mathbf{y}) = |\langle \phi(\mathbf{x}) | \phi(\mathbf{y}) \rangle|^2 \in [0, 1].$$

4. **Cómo se calcula**. Aplicar $U(\mathbf{y})$, luego $U(\mathbf{x})^\dagger$, y medir: $\Pr(0 \cdots 0) = K(\mathbf{x}, \mathbf{y})$. Con N repeticiones, error $\sim 1/\sqrt{N}$.
Ya probado en Qiskit: exacto 0.8108, estimado con 10 000 disparos 0.8118.
5. **Qué es cuántico y qué clásico**. Solo la matriz K es cuántica. Se mete en el dual como cualquier kernel: optimización clásica, convexa, con óptimo global.
6. **Hace falta entrelazamiento**. Sin él, el estado es producto, el kernel se factoriza y se calcula clásicamente. Por eso se usan CNOT (ZZFeatureMap).
7. **Qué voy a hacer**. SVM dual de margen suave propia, validada contra `sklearn`; kernel cuántico con circuitos propios, comprobado con `FidelityQuantumKernel`; comparación lineal / RBF / cuántico; limitaciones (disparos, concentración).
8. **Aporte matemático**. Demostrar que el kernel cuántico es semidefinido positivo: con $\rho(\mathbf{x}) = |\phi(\mathbf{x})\rangle\langle\phi(\mathbf{x})|$, $K(\mathbf{x}, \mathbf{y}) = \text{Tr}[\rho(\mathbf{x})\rho(\mathbf{y})]$, un producto escalar entre matrices.

Frase de cierre

“El objetivo no es demostrar que lo cuántico gana, sino entender **cuándo puede aportar algo y cuándo no**, con una implementación propia de principio a fin.”

Qué llevo hecho (enseñar el cuaderno impreso)

- **SVM**: teoría completa (primal, dual, KKT, kernels, margen suave) y código propio (primal por subgradiente, dual con `scipy`).
- **Cuántica**: lecciones 1–3 del curso de IBM (un sistema, varios sistemas, circuitos), con demostraciones.
- **Qiskit**: funcionando, 22 experimentos verificados; el último ya estima un kernel cuántico.

Qué quiero que me valide

- **Estructura**: SVM $\rightarrow$ kernels $\rightarrow$ fundamentos cuánticos $\rightarrow$ kernels cuánticos $\rightarrow$ experimentos $\rightarrow$ limitaciones.
- **Plan**: octubre, dual de margen suave y SVM propia “enchufable”; noviembre, QSVM completa con `ZZFeatureMap`; diciembre, experimentos y limitaciones.

Preguntas para Luis

1. Normativa y plantilla de la facultad; extensión esperada.
2. Fecha límite de depósito para febrero.
3. ¿Simulador o hardware real de IBM?
4. Uso de herramientas de IA: ¿qué espera que declare?

2. Cómo llegué al tema: ruta y artículos

La ruta

1. **El dual de la SVM.** Los datos solo aparecen como productos escalares $\Rightarrow$ truco del kernel y espacios de características (*feature spaces*).
2. **Google Scholar:** “quantum support vector machine” $\Rightarrow$ Rebentrost et al. (2014), la QSVM original.
3. **“Citado por” de Rebentrost** y, dentro, buscar “feature spaces” $\Rightarrow$ Havlíček et al. (2019): solo el kernel es cuántico. **Es el enfoque del TFG.**
4. **Marco teórico y límites:** Schuld y Killoran (2019); Liu et al. (2021) para la ventaja demostrada; Thanasilp et al. (2024) para la concentración.

Los artículos y qué aporta cada uno

Rebentrost, Mohseni y Lloyd (2014) — el punto de partida

Quantum support vector machine for big data classification. Physical Review Letters 113, 130503.

Qué dice: la primera SVM cuántica; resuelve **toda** la SVM en el ordenador cuántico, con ventaja exponencial teórica.

Por qué no lo sigo: necesita un ordenador cuántico tolerante a fallos, que hoy no existe.

Havlíček et al. (2019) — el artículo base del TFG

Supervised learning with quantum-enhanced feature spaces. Nature 567, 209–212.

Qué dice: solo el **kernel** se calcula en el ordenador cuántico; la SVM es clásica. Propone el mapa con entrelazamiento (ZZFeatureMap) y lo ejecuta en hardware real de IBM.

Por qué lo sigo: es viable con los ordenadores actuales y encaja con la SVM que ya tengo.

Schuld y Killoran (2019) — el marco teórico

Quantum machine learning in feature Hilbert spaces. Physical Review Letters 122, 040504.

Qué dice: codificar datos en estados cuánticos **es** un mapa de características, y el producto interno entre estados **es** un kernel. Conecta formalmente lo cuántico con la teoría de kernels.

Liu, Arunachalam y Temme (2021) — la ventaja demostrada

A rigorous and robust quantum speed-up in supervised machine learning. Nature Physics 17, 1013–1017.

Qué dice: construye un problema (basado en el logaritmo discreto) donde un kernel cuántico clasifica bien y **se demuestra** que ningún método clásico eficiente puede. La ventaja existe, al menos para datos con la estructura adecuada.

Thanasilp, Wang, Cerezo y Holmes (2024) — la limitación

Exponential concentration in quantum kernel methods. Nature Communications 15, 5200.

Qué dice: con muchos qubits, los valores del kernel se concentran en torno a un mismo número; con disparos finitos la matriz K se vuelve casi constante y la SVM no aprende.

Cómo encajan (la conclusión)

Rebentrost abre la idea $\rightarrow$ Havlíček la hace viable hoy $\rightarrow$ Schuld y Killoran le dan el marco de kernels $\rightarrow$ Liu et al. prueban que puede haber ventaja $\rightarrow$ Thanasilp et al. marcan el límite. **Conclusión:** merece la pena estudiarlo, pero la ventaja depende de los datos y del número de qubits.

3. El truco del kernel, paso a paso

Todo está en la Sección 1 del cuaderno del TFG.

Paso 1. Solo hacen falta productos escalares

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^T \mathbf{x}_j), \quad f(\mathbf{x}) = \text{sign} \left(\sum_{i \in SV} \alpha_i y_i (\mathbf{x}_i^T \mathbf{x}) + b \right).$$

Los datos nunca aparecen sueltos, solo como productos escalares.

(Apuntes: “Formulación Dual y Vectores de Soporte” y caja “Entendiendo la Función de Decisión”)

Paso 2. Datos no separables: subir de dimensión

Se usa $\phi: \mathbb{R}^d \rightarrow \mathcal{H}$ no lineal; en $\mathcal{H}$ quizá sí haya hiperplano. Como el dual solo usa productos escalares, basta conocer $\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$.

(Apuntes: inicio de “El Truco del Núcleo” y caja “Espacio de Hilbert”)

Paso 3. El kernel

$K(\mathbf{x}, \mathbf{y}) = \langle \phi(\mathbf{x}), \phi(\mathbf{y}) \rangle_{\mathcal{H}}$. El truco: cambiar $\mathbf{x}_i^T \mathbf{x}_j$ por $K(\mathbf{x}_i, \mathbf{x}_j)$ en el dual. La SVM trabaja en $\mathcal{H}$ **sin calcular nunca** ϕ .

(Apuntes: caja “Definición Formal: Función Kernel”)

Paso 4. Ejemplo con números

$\phi(\mathbf{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$, $\mathbf{x} = (1, 2)$, $\mathbf{y} = (3, 1)$.

- Camino largo: $\phi(\mathbf{x}) = (1, 2\sqrt{2}, 4)$, $\phi(\mathbf{y}) = (9, 3\sqrt{2}, 1)$, $\phi(\mathbf{x})^T \phi(\mathbf{y}) = 9 + 12 + 4 = 25$.
- Con el kernel: $(\mathbf{x}^T \mathbf{y})^2 = (3 + 2)^2 = 25$.

Mismo resultado calculando solo en $\mathbb{R}^2$. (Apuntes: caja “La magia del Kernel”)

Paso 5. RBF: dimensión infinita

$K(x, y) = e^{-\gamma(x-y)^2} = e^{-\gamma x^2} e^{-\gamma y^2} e^{2\gamma xy}$, y $e^{2\gamma xy} = \sum_{k \geq 0} \frac{(2\gamma)^k}{k!} x^k y^k$, luego

$$\phi(x) = e^{-\gamma x^2} \left(1, \sqrt{2\gamma} x, \sqrt{\frac{(2\gamma)^2}{2!}} x^2, \dots \right).$$

Infinitas coordenadas: ϕ es incalculable, pero K es una exponencial.

(Apuntes: caja “¿Qué hacen estos Kernels en la práctica?”)

Pasos 6 y 7. Kernel válido $\Rightarrow$ problema convexo

K es kernel $\iff$ toda matriz de Gram $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$ es semidefinida positiva. Entonces el dual es cóncavo: todo óptimo local es global.

(Apuntes: cajas “Caracterización de los kernels y Teorema de Mercer” y “Converidad y Óptimos Locales vs. Globales”)

El enlace con lo cuántico

“El kernel cuántico es esto mismo con $\mathcal{H} = \mathbb{C}^{2^n}$ y $\phi(\mathbf{x}) = |\phi(\mathbf{x})\rangle$. Como en el RBF, el espacio es enorme y no se calcula ϕ : el ordenador cuántico estima K directamente. Mi aporte es demostrar que su matriz es siempre semidefinida positiva, así que el dual sigue siendo convexo.”

4. ¿Por qué aplicarlo a la cuántica?

Por qué es prometedor

1. **Encaja de forma natural.** La SVM solo necesita productos escalares, y la mecánica cuántica es una teoría de productos internos en espacios de Hilbert.
2. **Kernels que lo clásico no puede calcular.** No basta con la dimensión 2^n (el RBF ya es de dimensión infinita). Lo importante es que, con entrelazamiento, se cree que simular esos estados es muy difícil clásicamente: el kernel solo sería eficiente en un ordenador cuántico. (*Havlíček et al.*)
3. **Ventaja demostrada en algún caso.** Hay un problema de clasificación donde el kernel cuántico gana y se demuestra que ningún método clásico eficiente puede. (*Liu et al.*)
4. **Viable hoy.** Circuitos cortos, sin parámetros que entrenar; el aprendizaje es la SVM clásica, convexa. Evita las *barren plateaus* de los clasificadores variacionales.

Por qué no es automático

- **Depende de los datos.** En datos “normales” (Iris, billetes) un RBF suele igualar o superar al kernel cuántico.
- **Concentración exponencial.** Con muchos qubits, K se vuelve casi constante y la SVM no distingue. (*Thanasilp et al.*)
- **Coste.** Cada entrada se estima con miles de repeticiones, y hay $\sim m^2/2$ entradas para m datos.

Frase para la reunión

“Es interesante porque el ordenador cuántico calcula de forma natural lo único que necesita la SVM, y puede dar kernels que un ordenador clásico no sabe calcular de forma eficiente, con ventaja demostrada en algunos problemas. Pero no ayuda siempre: depende de los datos y tiene limitaciones como la concentración. **Mi trabajo es implementarlo y estudiar cuándo aporta algo de verdad.**”

Si pregunta “¿y por qué no Rebrost?”

“Porque resuelve toda la SVM en el ordenador cuántico y necesita hardware tolerante a fallos, que no existe. Havlíček solo usa el ordenador cuántico para el kernel, así que funciona en los ordenadores de IBM de hoy.”